基于反事实声学残差与多尺度时序表征的语言无关语音表达建模及跨语言重建

Language-Independent Vocal Expression Representation and Cross-Lingual Reconstruction via Counterfactual Acoustic Residuals and Multiscale Temporal Modeling

研究论文初稿·2026 年 10 月 10 日

论文类别：研究假设与方法论文（Research Hypothesis & Methodology Manuscript）
拟议方法名称： CREAM —Counterfactual Residual Expression Analysis and Mapping（反事实残差表达分析与映射）
研究状态：理论与实验方案已提出；尚未训练模型、采集新实验数据或获得实验结果。
关键词：语音表达；反事实声学基线；韵律残差；多尺度时序建模；跨语言语音合成；情感计算；表达保真度

摘要

跨语言语音翻译和配音技术在语义准确性、声纹保持与自然度方面持续进步，但情绪、语气、强调、犹豫和节奏等**时变语音表达信息**仍然难以用统一、可解释的形式提取并在目标语言中重建。现有工作分别探索了连续情感识别、多尺度基频（F0）分解、自监督情绪表征、表达性语音翻译及情感保真语音编码。然而，将表达视为相对于语言特定、说话人特定的正常发音基线的**声学偏离过程**，并系统检验其跨语言可迁移性的统一研究方案仍有待明确验证。

本文提出 CREAM 研究框架。其核心思想是：在语义内容、语言、说话人和音韵结构约束下估计**反事实中性声学基线**，从实际语音中提取可解释的标准化表达残差；再以多尺度变换与声学通道间的时序耦合表示这些残差，并借助跨语言语义事件对齐，将源表达信号映射至目标语言的合法韵律空间。本文给出建模方程、可识别性边界、训练目标、数据构建方案、受控对照实验、感知评估及明确的可证伪标准。

本文**不报告尚未实施的实验结果**，也不宣称找到普适或唯一的“情感物理量”。其主要贡献是将一个可讨论的概念转化为可以通过实验否定或支持的科学命题：**在相同模型能力和数据条件下，相对于语言条件中性基线的多尺度表达残差，是否比直接声学特征或无约束风格嵌入更能保留跨语言听觉表达的一致性**。

1. 引言

声音信号处理存在成熟的分析—表征—变换—重建链路。对于声压波形 $x(t)$，时频分析可提取幅度、频率、相位及调制结构，再服务于编码、降噪、检测和合成。本文借用这一研究范式，但不假设人类情感自身具有类似傅里叶分解的线性、正交或唯一物理坐标。

考虑一句英语 “*I cannot believe you did that.*”：说话者可能在开头压低声音，在 *believe* 处提高基频和音强，并在句末以紧张或讽刺的音质收尾。如果系统将整句话编码为 *angry = 0.8*，表达中的转折、峰值位

置和语义强调便会丢失。若直接复制源语音的 F0 曲线到普通话译文，还可能破坏普通话词汇声调，从而影响可懂度。真正需要保留的并非原始声学轨迹，而是跨语言可以重新实现的**表达意图与听觉效果**。

因此，本文将研究对象界定为 **vocal expression（语音表达）**，包括但不限于情绪唤醒度与效价、强调、确定性、犹豫、语速、停顿、紧张度和非言语发声事件。这里的“语言无关”指**在指定评价维度上具有跨语言迁移能力**，而非所有语言、文化和语境下完全相同的表达符号。

研究问题为:

RQ1：从真实声学观测中减去语言、音韵和说话人条件下的中性基线，是否得到更稳定的跨语言表达信息?

RQ2：残差的多尺度动态及声学通道之间的时序耦合，能否提供超出 F0/能量单通道统计的表达信息?

RQ3：语义事件对齐与目标语言约束下的残差重渲染，能否改善表达相似度，而不牺牲可懂度、自然度及声纹一致性?

2. 相关工作与研究缺口

2.1 情感线索与连续状态

Scherer [1] 将情感声音交流视为从发声者状态、声学线索到听者归因的链路，提示我们**声音携带的表达**与**听者推断的主观情绪**不可直接画等号。GeMAPS/eGeMAPS [2] 提供 F0、响度、频谱、音质和时间参数等标准化可测声学特征，但这些特征本身并不是情绪的物理基元。连续情感研究可对 valence/arousal 随时间的变化建模，并需处理听者标注延迟 [3]。

2.2 多尺度韵律与自监督表示

Luo 等 [4] 已使用连续小波变换分解情绪语音的 F0 时间尺度，因此**使用小波本身并非本研究首创**。emotion2vec [5] 通过帧级和语句级自监督目标学习情绪表示，显示跨语言任务上的潜力；但一个分类友好的表征不必然能充当可解释、可控、可逆的表达重建变量。

2.3 跨语言表达保留与情感编码

SeamlessExpressive [6] 已研究跨语言语音翻译中的表达、语速和停顿保持。AffectCodec [7] 在神经语音编码中显式保护情感线索，这进一步说明“情感保真编码”不是空白领域。然而，**仅在压缩后保存情感**与**在改变语言及语义—音韵实现形式后重新表达相似意图**是不同任务。已有情绪相似度评估工作 [8] 也警示：简单的情绪嵌入余弦相似度不足以替代真实听者判断。

2.4 音系结构与语言差异

普通话中 F0 同时承载词汇声调和句子语调，两者会协同或冲突 [9]。2026 年的跨语言情感韵律研究还显示了跨语言共有线索与语言特定敏感性的并存 [10]。这意味着不能将“原曲线复刻”作为表达迁移的标准答案。

研究缺口：已知工作分别处理 特征提取、连续情感、表达风格嵌入 与 生成；尚需系统测试：**反事实中性基线 + 结构化声学残差 + 多尺度通道耦合 + 语义事件重定位**这个组合，是否能够建立更强的可解释性、迁移性和可重建性。此处的“缺口”为截至本文撰写时对所核验核心文献的判断，不是经过系统综述后对全部研究的排他性首创宣称。

3. 科学假设与研究范围

本文提出四条**预注册候选假设**:

- **H1（残差迁移假设）**：控制语言、说话人、语音内容和模型容量后，基于中性基线的标准化声学残差，在未见说话人、跨英中条件下的表达相似度优于直接使用原始声学轨迹。
- **H2（多尺度耦合假设）**：保留 F0、强度、时长、音质等多个通道的多尺度动态与相对时序，比单通道/单尺度特征更有利于表达重建。
- **H3（事件对齐假设）**：以语义事件与韵律焦点对应关系进行重定位，比基于绝对时间、线性伸缩或纯声学 DTW 的迁移更有利于保持译文中的强调和语气转折。
- **H4（受约束重建假设）**：在音系约束下进行表达重渲染，能够提高人类感知的表达匹配度，且不造成超过预注册阈值的可懂度、声纹或自然度下降。

本文不验证“真实内在情绪一定可由语音唯一识别”的命题。研究目标是**声学及感知层面的表达传递**，不是可靠推断个人心理状态。

4. 数学定义与 CREAM 方法

4.1 表达信息的观察模型

设 $x_s(t)$ 是源语言 ℓ_s 中、说话人 s、内容 c_s 的语音。声学分析器提取:

$$\mathbf{p}_s(t) = \mathcal{A}(x_s(t)) = [\log F_0, \log E, Q, \mathbf{d}, \mathbf{b}, ...](t), \tag{1}$$

其中 F_0 为有声区域基频；E 为校准/归一化后的能量或响度；Q 包括谱倾斜、HNR、气声/紧喉等音质线索；**d** 是音素/音节时长与局部语速；**b** 是停顿及非言语事件。**无声帧中的 F0 不进行非法插值**，以掩码 $m_v(t)$ 记录有声性；事件型变量采用事件序列而非强制解释为连续物理波形。

4.2 反事实中性基线（核心提议一）

设中性表达条件为 a_0。在理想情况下，定义语音内容、语言、说话人及音韵上下文 u 条件下的中性声学基线:

$$\mathbf{B}_\theta(c, \ell, s, u; t) \equiv \mathbb{E}[\mathbf{p}(t) \mid c, \ell, s, u, \mathrm{do}(a = a_0)]. \tag{2}$$

式（2）是**因果目标定义**，并不意味着可以仅凭任意观察数据识别该干预期望。优先采用同一说话人、同一文本的中性与表达性配对录音估计；其次以有明确偏差模型的中性 TTS/语音预测器近似。不同说话者、语体和情景必须接受单独校准。

对适于连续建模的通道，定义标准化残差:

$$\mathbf{r}_s(t) = \mathbf{M}(t) \odot \frac{\mathbf{p}_s(t) - \mathbf{B}_\theta(c_s, \ell_s, s, u; t)}{\sigma_\theta(c_s, \ell_s, s, u; t) + \epsilon}. \tag{3}$$

其中 **M** 是有效观测掩码，σ 是条件下自然变异尺度，ϵ 防止分母退化。时长更适合使用 $\log(d_{obs}/d_{base})$；停顿使用事件概率或长度分布的偏差。式（3）因此是**混合类型的标准化残差集合**，并非把所有变量机械相减。

例如，中性 F0 目标既受英语句重音影响，也受普通话词汇声调影响。若残差确实捕捉表达信号，就应使“同一种表达方式”在不同语言中具有相近的可迁移表示，而保留目标语音的合法音系信息。

4.3 多尺度残差与时序耦合（核心提议二）

对每个连续通道 $r_k(t)$ 构建多尺度表征：

$$W_k(\tau, a) = \frac{1}{\sqrt{|a|}} \int r_k(t) \psi^* \Big(\frac{t-\tau}{a} \Big) \, dt, \tag{4}$$

其中 ψ 为母小波，a 表示时间尺度，τ 表示位置。实验中采用候选离散小波/连续小波及可学习时序卷积进行对照，以排除“多参数网络自然更好”的解释。

仅分析幅值仍不充分。引入声学通道间的跨小波相干性或局部时滞：

$$\Gamma_{ij}(\tau, a) = \mathrm{coh}\{W_i(\tau, a), W_j(\tau, a)\}, \quad \delta_{ij}(\tau, a) = \mathrm{lag}(r_i, r_j). \tag{5}$$

本研究所称“表达相位”仅指**声学变量峰值与语音事件之间的相对时序关系**，不预先假设情感有可独立测量的物理相位。通过打乱通道间的相对时序但保留各通道边缘统计，测试这种协调关系是否真的影响听者判断。

4.4 语言条件解耦与结构化表达空间

在韵律事件坐标 u（词重音、音节核、短语边界、语义焦点）上，用编码器得到：

$$\mathbf{z}_s(u) = f_\phi(\mathbf{r}_s, \mathbf{W}_s, \Gamma_s, \mathbf{a}_s, \mathbf{h}_s), \tag{6}$$

其中 $\mathbf{a}_s$ 为语义事件/时间对齐信息，$\mathbf{h}_s$ 是可选上下文。为保留解释性，$\mathbf{z}$ 被划分为（i）可观测表达残差轨迹；（ii）低维潜在表达因子；（iii）非言语表达事件。潜在维度通过验证集和消融实验确定，不预设 valence、arousal 等一定构成完整基底。

使用内容/说话人/语言判别对抗项或互信息惩罚，**降低不必要的泄漏**；但不会强制绝对独立：语言中的声调、句法焦点和文化性表达方式与可感知的情绪不可完全分离。纯粹要求 $I(\mathbf{z}; \ell) = 0$ 可能降低表达保真，故把“低泄漏”当作权衡目标，评估 Pareto 曲线，而不是公理。

4.5 语义事件重定位与目标语音重渲染（核心提议三）

给定译文 c_t 与目标语言 ℓ_t，建立源/目标语义事件图的软对齐映射 Π。此映射允许词序不同导致的非单调对应，但每个目标短语内部保留合法音节时序。经重新采样和聚合得到目标表达轨迹：

$$\tilde{\mathbf{z}}_t(u_t) = \sum_{u_s} \Pi(u_t, u_s) \mathbf{z}_s(u_s). \tag{7}$$

目标语言的基线不是源基线；由目标内容、音系和目标说话人条件重新估计 $\mathbf{B}_t$。表达渲染器预测受限声学偏离：

$$\hat{\mathbf{p}}_t(t) = \mathbf{B}_t(t) + \sigma_t(t) \odot G_\omega(\tilde{\mathbf{z}}_t, c_t, \ell_t, s_t; t), \tag{8}$$

并以音系约束算子 $\mathcal{C}_{\ell_t}$ 调整 F0/时长及可懂度相关变量。最终：

$$\hat{x}_t = \mathrm{TTS}_\eta\left(c_t, s_t, \mathcal{C}_{\ell_t}[\hat{\mathbf{p}}_t]\right). \tag{9}$$

实际实现中，如果 TTS 不支持显式 F0、音质和节奏控制，就采用 reference encoder、prosody tokens、可训练适配器或声学后处理；这些实现应独立报告其控制带宽和限制。

4.6 目标函数与避免指标投机

候选训练目标：

$$\mathcal{L} = \lambda_1\mathcal{L}_{acoustic} + \lambda_2\mathcal{L}_{expression} + \lambda_3\mathcal{L}_{event} + \lambda_4\mathcal{L}_{ling} + \lambda_5\mathcal{L}_{speaker} + \lambda_6\mathcal{L}_{regularize}. \tag{10}$$

表达损失结合有人工标注的连续情感轨迹、可解释通道时序一致性及与听者偏好相关的独立判别器。语言约束用于声调/音素识别与文本准确度。推理时可进行“分析—合成—再次分析”的反馈优化，但**反馈模型不得与最终评估模型或听者标注共享不可分离的偏差**，否则容易出现指标投机。

5. 可识别性、理论命题与边界

命题 P1（在强条件下的残差可识别性）。如果同一说话人、同一语言、同一文本、同一语境存在经过配对的中性与表达性语音；声学通道具有相容的时间对齐；采录条件被控制；中性表达有可操作的标定标准，那么式（3）对应的**条件声学偏差**在测量误差界限内可以估计。

不能据此推出：（a）唯一的生理情绪状态；（b）跨文化普适的一一对应情绪坐标；（c）潜变量 $\mathbf{z}$ 可被无条件唯一识别。若 $\mathbf{z}$ 只通过编码器—解码器重建来训练，那么任意可逆变换 $h(\mathbf{z})$ 可与相应逆解码器组合并保持相同重建，故**潜在空间至多在某一等价类中可识别**。为增加可解释性，需要外部锚点（人工标注、独立声学观测、介入控制、相同语义跨语言配对）与干预实验。

命题 P2（被检验而非预设的跨语言性）。若 $\mathbf{r}$ 确实降低了语言特定的音系贡献，则在未见语句和说话人的条件下，同一表达目标的跨语言表征距离应小于不做基线消除的表征距离；但这一关系可能只在 arousal、强调或紧张度等部分维度成立，而不适用于讽刺或社会文化含义强的表达。此命题是**待测经验假设**，不是已经证明的定理。

6. 研究设计：数据、对照与实施步骤

6.1 双轨数据集

轨道 A：现有基准。使用 ESD（20 名英/中文说话人、五类情绪、约 29 小时语音）作为同语言中性—表达残差学习和初始跨语言迁移的基准 [11]。注意 ESD 包含英、中文样本，但**并不自动提供逐句语义等价的英中翻译对**；不能把同编号文本误用为跨语言语义对齐的金标准。补充 RECOLA/SEWA 类连续情感数据用于轨迹预测预训练，不将其当作英语—中文翻译语料 [3]。

轨道 B：专门建立的受控双语验证集。拟征集 24–40 名成年说话人，设计 150–250 组双语语义等价短句，覆盖中性、强调、焦虑、兴奋、悲伤、惊讶、犹豫、讽刺等表达功能。每个语义单元提供可审查译文、焦点/重音事件、同说话人中性/表达性复述（尽可能）及录制元数据。未能双语流利朗读的说话人以语言组独立录制，

不强求“相同人双语”这一可能产生不自然表达的条件。以上人数和条目是**实验规划值而非已完成样本数**；应以功效分析、预算和先导实验确定最终规模。

人工标注采用两类：连续 valence/arousal 或强度轨迹（含反应时校正）；以及句级/片段级的强调位置、表达意图、感知相似度、自然度和可懂度。至少三名标注者对每个评价片段进行标注；保留分歧分布，不以简单均值伪装客观真值。

6.2 模型对照

模型	结构说明	检验目的
B0：中性目标 TTS	只输入目标文本/声纹	无表达迁移下限
B1：直接声学映射	标准化 F0、energy 等直接转移，配合时长调整	原始特征基线
B2：情绪标签条件 TTS	句级离散标签或 arousal/valence 条件	离散/低维情绪基线
B3：学习式风格嵌入	通用 reference-style encoder + 同一生成器	无显式残差的学习基线
B4：表达式语音翻译	可复现许可条件下的 SeamlessExpressive 或同类可用模型	端到端外部参照
M1：仅残差	式（3），不含多尺度耦合	检验 H1
M2：残差 + 多尺度	加式（4），不含跨通道时序	检验 H2 的尺度部分
M3：残差 + 多尺度 + 耦合	加式（5）	检验 H2 的协同部分
M4：完整 CREAM	M3 + 语义事件对齐 + 音系约束重建	检验 H3/H4

公平性约束：B1–B3 与 M1–M4 尽量使用相同声学特征提取器、相同译文、相同说话人条件、相同目标 TTS、近似训练预算；无法统一条件的外部模型 B4 **只能作为参考结果，不能用于严格归因**。

6.3 分阶段实验与消融

E1：验证残差而非情绪标签。在中性/表达性配对的相同文本上预测基线并提取残差；用说话人分离、文本分离、语言分离的数据切分测试跨域检索及连续情绪预测。报告模型失误在何处来自“中性基线”估计偏差。

E2：验证时间尺度与通道相位。比较固定小波、多尺度卷积、单尺度统计；执行“通道时间打乱”负对照，保持单通道分布不变但破坏 F0—能量—音质与重音事件的同步关系，检验听觉变化是否显著。

E3：验证英—中跨语言表达重建。对每组源句产生目标文本相同、声纹条件相同的 B0–M4 译音。目标包含英语 → 普通话、普通话 → 英语两方向；按是否包含强制词重音、词汇声调冲突、讽刺、停顿和非言语事件分层分析。

E4：验证最小充分特征集合。依次删除 F0、响度、时长、音质、语义事件、跨通道耦合及潜在风格部分；以“表达匹配—语音可懂—控制维度数”的 Pareto 前沿寻找较小但有效的表征，而非主观指定有限的“情感物理基元”。

6.4 主观与客观评估

唯一预注册主要终点（Primary endpoint）：在未见说话人与未见文本的英 ↔ 中测试集上，采用参考源语音 A 与两段目标语音 B/C 的盲法 *two-alternative forced choice*（2AFC），询问“哪一段在语气、情绪强度、强调位置及节奏上更接近 A，而非哪一段更自然”。主比较设为 **完整 CREAM（M4）vs. 无残差的匹配风格嵌入模型（B3）**。分别报告双语言方向的效应。

次要终点： (1) valence/arousal 的一致性相关系数 CCC（需校准感知标注延迟）；(2) 与人工判断校准的情绪相似度指标（例如 SES-Bench/SES-Judge 思路，若可公开复现）[8]；(3) 语义/事件对齐后 F0、能量与停顿轨迹距离；(4) 目标语言 ASR-WER/CER、普通话声调错误率及关键词可懂度；(5) 目标自然度 MOS/CMOS；(6) 说话人验证相似度；(7) 表达片段与非言语事件的精准保留率。

建议在每种语言方向招募 30–50 名合格听者，进行随机化、平衡化、盲法样本展示；实际人数通过先导效应量和功效分析确定。主要终点以含模型条件固定效应、听者和语句随机效应的混合效应逻辑回归分析；报告效应量、95% 置信区间和预注册的显著性阈值。次要比较进行 Holm 校正，提供说话人及语句级 bootstrap 稳健性分析。所有音频应进行响度和技术质量匹配，防止“哪段更响”污染情感判断。

7. 预期结果、失败标准和替代理论

本文不将预期作为发现。下表定义**将支持何种解释，以及何种情况会否定原假设**。

假设	若成立，预计观察	可证伪/不支持标准
H1	M1 在跨语言表达相似度优于 B1/B3 的对应配置	效果无改善，或提升只源于同文本/同说话人泄漏
H2	M3 优于 M2；打乱通道同步后感知下降	耦合特征无增益，或仅由模型参数量解释
H3	语义事件对齐优于线性伸缩/DTW，强调落点更合理	效果相当或更差，尤其在词序重排语句中
H4	M4 表达匹配提升，且可懂度/自然度在预注册非劣界内	表达提升以明显语义错误、声调错误或自然度下降换取

重要的替代解释：语言内声学基线比直接声学特征更接近“去个性化”归一化，但并不构成真正的语言无关表示；表达轨迹可能是高度文化依赖的；声音中某些情绪依赖句子语义而不能从残差独立解析；中性参考语音本身包含态度与句法焦点，可能删除研究目标信息。这些解释都要求在分析中与论文假设并行检验。

8. 科学意义、创新边界与可复现性

本文的潜在新意是一个组合性、可证伪的机制假说，不是某一个算法名称：

1. **反事实参照**：定义语言/音韵/说话人条件下的中性预期，并将表达建模为相对偏离；通过配对采集和误差敏感性分析讨论识别条件。
2. **结构化多尺度表达信号**：把可观测声学残差、通道间相对时序和潜在表达因子分开，测试其各自的感知贡献，而不是把情感当一个静态标签。
3. **目标语音重新实现而非照搬**：在语义事件锚点和目标语言音系约束下重建表达，实现“相似表达意图、不同实际声学实现”的研究目标。

4. **主观感知与约束的联合可证伪评价**：设置独立的听者匹配任务，同时防止通过损害可懂度、自然度或声纹来伪造表达提升。

需要承认：情绪声音模型、基频小波转换、表达性语音翻译、风格迁移与情绪 codec 已有相当积累 [1–8,11]。在正式投稿前，必须补做系统文献检索、近邻模型复现和完整实验；在完成之前不能合法或科学地宣称“世界首次”。

为保证可复现，建议公开：数据清单与合法授权说明、文本/说话人分割索引、预处理配置、基线估计方法、特征/训练代码、预注册实验协议、标注指南、主评估匿名化音频样例、置信区间计算脚本，以及失败案例和消融结果。限制公开原始声纹可能更符合参与者授权与隐私要求。

9. 伦理与局限

第一，声音的可测表达线索不能直接证明某人的真实心理状态，模型输出应明确标记为**感知表达估计**而非人格或精神健康推断。第二，情感表达受语言、文化、语体、性别角色期待、说话环境及表演意图影响，不宜强迫所有文化映射到单一“普适”强度轴。第三，“中性”并非绝对无情绪，中性录音可能含话语功能所需的语调；应采用多种参照策略并测量系统偏差。第四，语音重现具有声音冒用风险；数据采集和模型展示需获得明确授权，并考虑水印、滥用检测、可撤回授权和防冒用约束。第五，本框架依赖 TTS 的可控性；即使表达表征有效，也可能因为生成器无法执行所需细粒度控制而失败，必须分别报告表示错误和生成错误。

10. 结论

本文将“对语音表达做信号处理”具体化为一项可检验的研究：以**反事实中性基线**分离语言与说话人相关的常规声学模式，将偏离量编码为**具有多尺度和通道耦合信息的连续表达轨迹**，再通过**语义事件对齐与目标音系约束**在另一语言中重新实现。这是一个研究命题，不是已证明的自然定律；其中的中性基线可识别性、语言迁移程度、跨通道时序价值和重建优越性，都由预注册对照实验决定。

如果 H1–H4 获得重复、显著且具实际大小的支持，CREAM 可成为一种兼具可解释性与生成能力的跨语言语音表达接口，用于配音、辅助交流和多语言内容制作。如果部分假设被否定，所积累的配对语料、评估协议和分解实验仍可揭示表达信息究竟保留在哪些变量中、哪些因素依赖语言，以及当前生成模型的真实能力边界。

参考文献

[1] Scherer, K. R. (2003). Vocal communication of emotion: A review of research paradigms. *Speech Communication, 40*(1–2), 227–256. DOI: 10.1016/S0167-6393(02)00084-5.

[2] Eyben, F., Scherer, K. R., Schuller, B. W., et al. (2016). The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing. *IEEE Transactions on Affective Computing, 7*(2), 190–202. DOI: 10.1109/TAFFC.2015.2457417.

[3] Khorram, S., & Mower Provost, E. (2021). Jointly Aligning and Predicting Continuous Emotion Annotations. *IEEE Transactions on Affective Computing, 12*(4), 1069–1083. DOI: 10.1109/TAFFC.2019.2917047.

[4] Luo, Z., Takiguchi, T., & Ariki, Y. (2016). Emotional Voice Conversion Using Neural Networks with Different Temporal Scales of F0 based on Wavelet Transform. *9th ISCA Speech Synthesis*

Workshop, 140–145. DOI: 10.21437/SSW.2016-23.

[5] Ma, Z., Zheng, Z., Ye, J., et al. (2024). emotion2vec: Self-Supervised Pre-Training for Speech Emotion Representation. *Findings of ACL 2024*, 15747–15760. DOI: 10.18653/v1/2024.findings-acl.931.

[6] Seamless Communication et al. (2023). Seamless: Multilingual Expressive and Streaming Speech Translation. *arXiv:2312.05187*. https://arxiv.org/abs/2312.05187.

[7] Shi, J., Du, H., Song, X., Hong, Y. A., Zhang, Y., & Gao, A. (2026). AffectCodec: Emotion-Preserving Neural Speech Codec for Expressive Speech Modeling. *Findings of ACL 2026*, 9102–9124. DOI: 10.18653/v1/2026.findings-acl.442.

[8] Tsai, Y.-S., Lin, Y.-C., Yang, C.-K., et al. (2026). Toward Human-Aligned Judgement of Speech Emotion Similarity. *arXiv:2609.32504*（预印本）. https://arxiv.org/abs/2609.32504.

[9] Liu, M., Chen, Y., & Schiller, N. O. (2022). Context Matters for Tone and Intonation Processing in Mandarin. *Language and Speech, 65*(1), 52–72. DOI: 10.1177/0023830920986174.

[10] Liu, L., et al. (2026). Universal and Language-Specific Influences on Emotional Prosody Production. *Speech Communication*（2026 年文献，见出版社页面）. https://www.sciencedirect.com/science/article/abs/pii/S016763932600124X.

[11] Zhou, K., Sisman, B., Liu, R., & Li, H. (2022). Emotional Voice Conversion: Theory, Databases and ESD. *Speech Communication, 137*, 1–18. DOI: 10.1016/j.specom.2021.11.006.

论文声明（2026-10-10）：本文为原创研究构想和实验研究方案。引文支持相关研究现状，不代表文中假设已获得实验验证；所有实验规模、指标和预期仅用于设计与预注册。投稿之前应补全系统文献检索、伦理审批、数据与基线复现、真实结果以及作者署名与贡献说明。